

STT / TTS 웹 애플리케이션

기능 명세서 (Functional Specification)

작성일자: 2026년 5월 29일

버전: v1.0

작성자: AI 시스템 설계 파트

1. 개요 (Overview)

본 문서의 목적은 OpenAI의 Whisper 모델과 Hugging Face 기반의 TTS 모델을 연동하여 웹 브라우저 환경에서 동작하는 음성 인식(STT) 및 음성 합성(TTS) 통합 웹 애플리케이션의 핵심 기능과 사양을 정의하는 데 있습니다. 사용자는 직관적인 Gradio 기반 웹 인터페이스를 통해 복잡한 설정 없이 브라우저 내에서 즉각적인 양방향 오디오 처리를 수행할 수 있습니다.

2. 시스템 아키텍처 및 기술 스택

시스템은 오픈소스 AI 모델과 경량화된 Python 웹 프레임워크를 결합하여 단일 스크립트 기반으로 빠른 배포가 가능하도록 설계되었습니다.

- **웹 프론트엔드 및 서비스 프레임워크:** Gradio (UI 구성 및 실시간 이벤트를 관리하는 웹 환경 제공)
- **음성 인식 (STT):** OpenAI Whisper **turbo** 모델 (고속 추론 특화 엔진)
- **음성 합성 (TTS):** Hugging Face 표준 패턴 기반 오픈소스 모델 (PyTorch 프레임워크 활용)
- **오디오 파일 처리:** Soundfile & OS 모듈 (임시 데이터 저장 및 포맷 인코딩 관리)
- **컴퓨팅 환경:** CPU 기반 추론 모델 구동 (안정성 및 범용성을 위해 fp16=False 설정)

3. 주요 기능 명세 (Core Features)

3.1. 음성 인식 기능 (STT - Speech to Text)

사용자의 마이크 입력을 실시간으로 캡처하고, 이를 고성능 음성 인식 모델로 해석하여 정형화된 텍스트 데이터로 변환합니다.

- **입력 명세:** Gradio 마이크 컴포넌트를 통해 수집된 완성형 오디오 파일 경로 (filepath 형태)
- **주요 연산 프로세스:**
 1. 사용자가 오디오 녹음을 완료하면 내부 임시 디렉토리에 파일이 생성됩니다.
 2. 오디오 파일 경로를 transcribe_audio 함수가 인계받습니다.
 3. Whisper 모델 로드 시 설정된 turbo 가중치와 최적화 옵션을 기반으로 CPU 추론 연산을 시작합니다.
 4. 한국어 인식 품질 극대화를 위해 인퍼런스 인자로 language="ko"를 명시적으로 전달합니다.

- **출력 명세:** 최종 받아쓰기가 완료된 한국어 문자열 (String)
- **예외 처리 사양:** 사용자가 음성 입력을 수행하지 않은 상태로 변환을 시도할 경우(오디오 파일 경로가 None인 상황), 시스템은 인퍼런스를 취소하고 "오디오 파일이 없습니다. 다시 녹음해 주세요."라는 명확한 예외 안내 메시지를 반환하도록 예외 분기를 수행합니다.

3.2. 텍스트 음성 변환 기능 (TTS - Text to Speech)

텍스트 상자에 입력된 문장을 문맥 지향적 인공지능 모델이 분석하여 인간에 가까운 자연스러운 음성 파형으로 변환합니다.

- **입력 명세:** 사용자가 UI 텍스트 영역에 직접 타이핑하거나 STT를 통해 전달된 임의의 문자열 데이터
- **주요 연산 프로세스:**
 1. Gradio 텍스트 컴포넌트의 입력 이벤트를 통해 TTS 변환 함수가 실행됩니다.
 2. PyTorch 텐서 기반으로 표현된 텍스트 스트림이 Hugging Face 사전 학습(Pre-trained) 모델에 주입됩니다.
 3. 생성된 원시 음성 파형(Waveform) 데이터를 soundfile 라이브러리를 통해 공인된 오디오 표준 규격 (예: .wav) 파일로 인코딩합니다.
 4. 로컬 서버 시스템 내 고유 경로에 임시 파일을 안전하게 기록 및 생성합니다.
- **출력 명세:** 웹 브라우저 내에서 직접 재생, 일시 정지 및 파일 다운로드가 가능한 형태의 오디오 플레이어 객체

4. 사용자 인터페이스(UI) 설계

사용자 인터페이스는 직관적인 상호작용과 자연스러운 흐름을 제공하기 위해 2단 배치 및 반응형 구조를 채택했습니다.

UI 컴포넌트명	Gradio 객체 타입	출력 텍스트/속성	기능적 역할 설명
메인 타이틀	gr.Markdown	 Whisper 녹음본 파일 기반 음성 인식 (STT)	최상단 영역에서 서비스 제목 및 목적을 고지하는 역할을 수행합니다.
사용 가이드 안내	gr.Markdown	마이크로 녹음을 진행한 뒤...	사용자가 서비스 조작 순서를 한 눈에 인지할 수 있도록 가이드를 안내합니다.
오디오 입력기	gr.Audio	sources="microphone" type="filepath"	브라우저 마이크 접근 권한을 획득하여 실시간 녹음을 지원하며 완료 후 파일 경로를 제공합니다.
변환 실행 버튼	gr.Button	 텍스트 변환하기 variant="primary"	클릭 이벤트를 통해 transcribe_audio 함수를 트리거하는 핵심 액션 컴포넌트입니다.

UI 컴포넌트명	Gradio 객체 타입	출력 텍스트/속성	기능적 역할 설명
결과 텍스트 창	gr.Textbox	lines=5 placeholder="..."	STT 변환 결과 문장을 출력하거나 TTS 변환을 위한 원천 텍스트를 기입 및 편집하는 공간입니다.

5. 예외 처리 및 향후 확장 고려사항

💡 시스템 성능 최적화 가이드

- 1. 모델 인프라 유연성:** 현재 리소스 효율화를 위해 Whisper turbo 및 CPU 환경을 기초로 설계되었으나, 고해상도 처리 및 속도 개선이 시급할 경우 인프라 구성 코드 단에서 device="cuda"로 단일 전환하여 고성능 GPU 인퍼런스로 즉각 확장이 가능합니다.
- 2. 파일 수명 주기 관리:** 오디오 녹음 및 TTS 합성이 다량 발생할 경우 로컬 스토리지에 임시 파일 누적이 유발될 수 있으므로, 웹 애플리케이션의 주기적인 유지보수 과정 혹은 세션 종료 시점에 임시 오디오 자원을 일괄 소거하는 가비지 컬렉션 처리가 권장됩니다.